P2 | RAG legislativo com evidências

MVP de IA generativa • Dificuldade: média

O que você vai construir

Um assistente que responde perguntas sobre proposições legislativas usando documentos oficiais recuperados de uma base. Cada resposta deve indicar de onde a informação veio. Se não houver evidência suficiente, o sistema deve dizer que não sabe.

Resultado esperado

- Base pesquisável de 1.000 a 5.000 documentos da Câmara.
- Fluxo RAG: pergunta → busca de trechos relevantes → resposta com fontes.
- API de consulta, conjunto de 50–100 perguntas de avaliação e registros de cada etapa.

Dados e ferramentas

- Fonte: Dados Abertos da Câmara dos Deputados (proposições, ementas, tramitações e documentos associados).
- Stack: Python, FastAPI, embeddings, Chroma/Qdrant/pgvector (escolha um), modelo de linguagem e MLflow para avaliação e tracing.
- Importante: LangChain é opcional; LangGraph e agentes não são necessários neste desafio.

Passo a passo

- 1. Selecionar: escolher um período e temas; coletar 1–5 mil documentos com ID, título, URL e data.
- 2. Limpar e dividir: transformar conteúdo em trechos (“chunks”) e manter a referência do documento de origem em cada trecho.
- 3. Indexar: gerar embeddings e armazenar trechos + metadados em um banco vetorial.
- 4. Recuperar: ao receber pergunta, buscar os top-k trechos mais relevantes.
- 5. Responder: enviar os trechos a um LLM com instrução para responder só com base neles e apresentar links/IDs das fontes.
- 6. Abster-se: quando as fontes não sustentarem a resposta, devolver “Não encontrei evidência suficiente nos documentos consultados.”
- 7. Expor: criar POST /ask e GET /health; registrar tempo de busca e geração separadamente.
- 8. Testar: criar perguntas com documentos esperados, perguntas sem resposta e casos ambíguos.

Como avaliar

- Busca: Recall@K e NDCG@K quando existir documento esperado para cada pergunta.
- Resposta: proporção de respostas com fonte válida e fidelidade ao conteúdo recuperado (groundedness).
- Segurança: frequência com que recusa corretamente responder sem evidência.
- Operação: latência p50/p95 e custo por pergunta, quando houver API paga.

Versão	Recall@K	Respostas com fonte válida
Busca por palavras (BM25)	A medir	A medir
Busca por embeddings	A medir	A medir
Embeddings + reranker (opcional)	A medir	A medir

Exemplo de uso

Pergunta: “Quais proposições recentes abordam educação digital?”
Resposta esperada: síntese concisa com indicação de proposições recuperadas e links oficiais. Sem documentos relevantes, resposta de incerteza. Não inventar números ou proposições.

Checklist de pronto

- [ ] Documentos e fontes rastreáveis por ID/URL; indexação reproduzível.
- [ ] Cada resposta inclui referências; ausência de evidência gera abstenção explícita.
- [ ] Golden set versionado de 50–100 perguntas, com casos sem resposta.
- [ ] Comparação reproduzível de pelo menos busca lexical vs. embeddings.
- [ ] Traces distinguem retrieval e geração; métricas de qualidade e latência registradas.
- [ ] README mostra arquitetura, benchmark, limitações, execução e demo.

Se sobrar tempo (opcional)

Adicionar reranker, interface web mínima ou filtros por ano/tema. Faça isso após medir a versão simples.

Fonte principal

Relatório anexado, seção “P2 — RAG legislativo com respostas citadas” (pp. 9–10). Dados oficiais: https://dadosabertos.camara.leg.br/